INFORME INTEGRAL DE ANÁLISIS

Regresión y clasificación para analítica de canciones

Análisis de resultados, comparación de experimentos, evaluación por género y aplicación de negocio

Resumen ejecutivo

El proyecto busca estimar la popularidad de una canción antes de su lanzamiento para apoyar decisiones de inversión promocional. El documento de pruebas registra un modelo de referencia lineal con una característica derivada de la duración, dos experimentos con Random Forest y dos con HistGradientBoosting. También documenta un modelo de clasificación logística que estima si una canción será hit.

En regresión, el modelo original obtiene el mejor resultado global registrado: MAE=5,75, RMSE=7,15 y R^2=0,718. Todos los modelos superan la línea base de MAE=10,44, pero los experimentos modificados no mejoran al modelo original. HistGradientBoosting 3 es el mejor de los experimentos propios por MAE (6,36); HistGradientBoosting 4 tiene el menor RMSE (7,98) y el mayor R^2 (0,649) dentro de esos experimentos. En clasificación, la regresión logística logra costo 99 frente a 318 de la línea base, con accuracy=0,858, precision=0,688, recall=0,811 y F1=0,745.

Los resultados se deben interpretar como evidencia de desempeño sobre el conjunto de prueba documentado, no como garantía de resultados comerciales. El propio sistema declara que los datos son sintéticos y que las asociaciones no constituyen evidencia causal.

1. Objetivo y alcance del análisis

El análisis cubre los resultados que aparecen en el documento fuente: salud y ficha de la API; predicciones individuales y por lote; modelo original de regresión; experimentos Random Forest 1 y 2; experimentos HistGradientBoosting 3 y 4; métricas desglosadas por género; modelo de clasificación logística; umbrales y costos de decisión; y observaciones de reproducibilidad y limitaciones.

El objetivo de negocio declarado es apoyar a una disquera en la decisión previa al lanzamiento sobre cuánto invertir en promoción. La regresión estima una popularidad entre 0 y 100 y utiliza un corte de promoción de 65 puntos. La clasificación predice es_hit=1 cuando la popularidad alcanza al menos 70, y usa un umbral probabilístico de 0,27 para decidir si promocionar.

2. Datos, variables y diseño de evaluación

Todos los modelos registrados usan la misma partición temporal: entrenamiento con 1.585 canciones de 1995 a 2019 y prueba con 415 canciones de 2020 a 2025. Esta separación simula una situación en la que se entrena con canciones de años anteriores y se evalúa en años posteriores, lo que resulta más cercano al uso previsto que una división aleatoria.

Las variables de entrada declaradas son:

Variable	Significado
bailabilidad	Qué tan adecuada es la canción para bailar, según la medida utilizada por los datos.
energia	Nivel de intensidad y actividad musical.
valencia	Medida asociada con el carácter positivo o alegre de la música.
acustica	Medida de qué tan acústica parece la canción.
tempo	Velocidad musical, normalmente expresada en pulsaciones por minuto.
duracion_min	Duración en minutos.
volumen_db	Medida de volumen o intensidad sonora registrada en los datos.
anio	Año de lanzamiento.
colaboracion	Indicador de si hay una colaboración, según la codificación del conjunto de datos.
genero	Género musical: pop, rock, indie, urbano o electrónica, entre otros valores admitidos.

Las variables excluidas en regresión son:

- reproducciones_sem1: se observa después del lanzamiento y no estaría disponible al tomar la decisión previa a la promoción.
- es_hit: se deriva de la variable objetivo (popularidad >= 70), por lo que introducirla en la regresión produciría fuga de información.

En clasificación se excluyen reproducciones_sem1 y popularidad, porque popularidad es el origen de la etiqueta es_hit. Esta decisión reduce el riesgo de que el modelo reciba información que no estaría disponible o que revele directamente la respuesta.

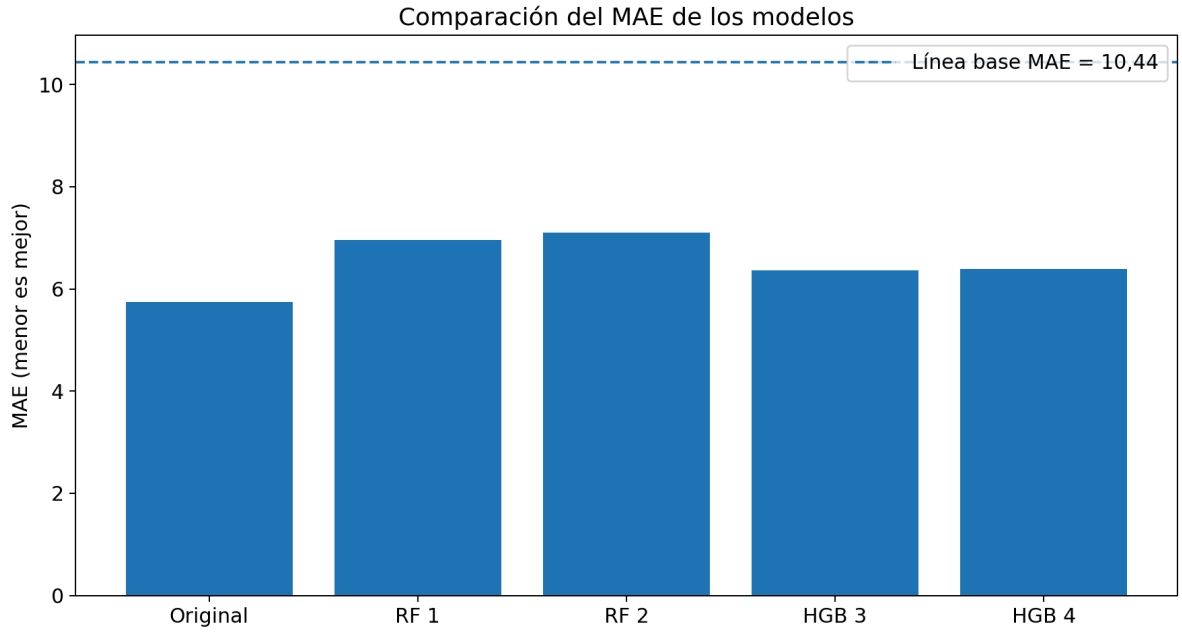
3. Métricas utilizadas

Métrica	Interpretación para este proyecto	Preferencia
MAE	Error absoluto promedio en puntos de popularidad; es fácil de interpretar en la escala 0–100.	Menor
RMSE	Penaliza más los errores grandes que el MAE.	Menor
R^2	Proporción de variabilidad de la popularidad explicada por el	Mayor

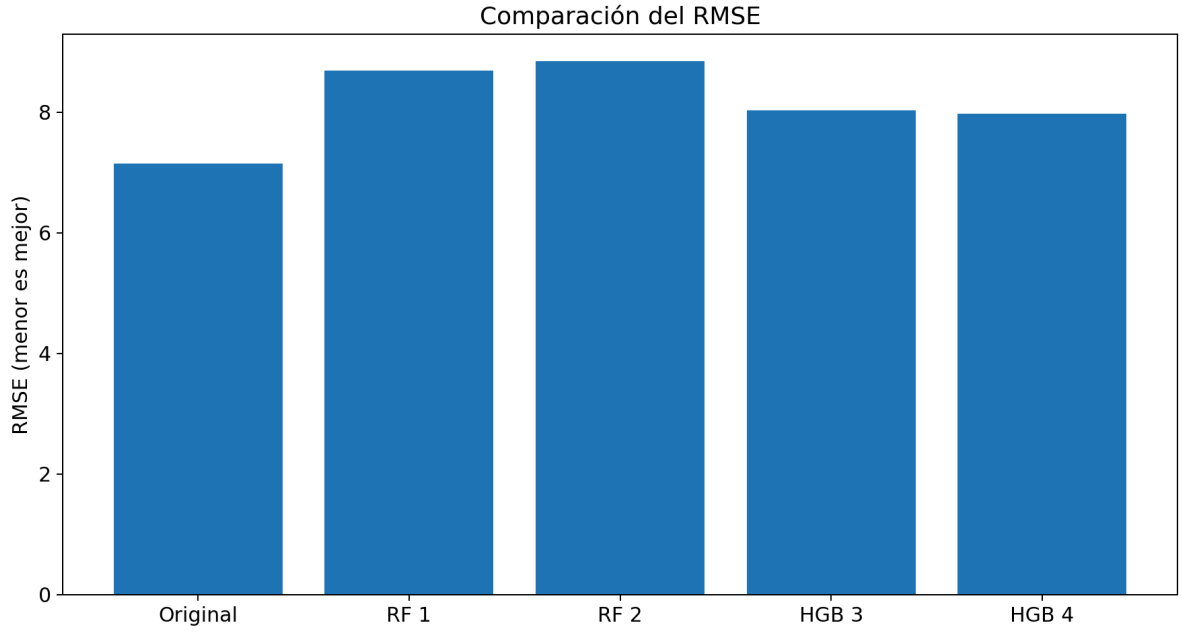
	modelo frente a la referencia de la media.	
Sesgo	Indica tendencia sistemática a sobreestimar o subestimar; su signo depende de la fórmula aplicada.	Cercano a 0
Accuracy	Proporción total de clasificaciones correctas.	Mayor, interpretada junto con otras métricas
Precision	De las canciones señaladas como hit, qué proporción realmente lo fue.	Mayor
Recall	De los hits reales, qué proporción fue detectada.	Mayor
F1	Media armónica entre precision y recall.	Mayor
Costo	Penalización definida por el proyecto para falsos positivos y falsos negativos.	Menor

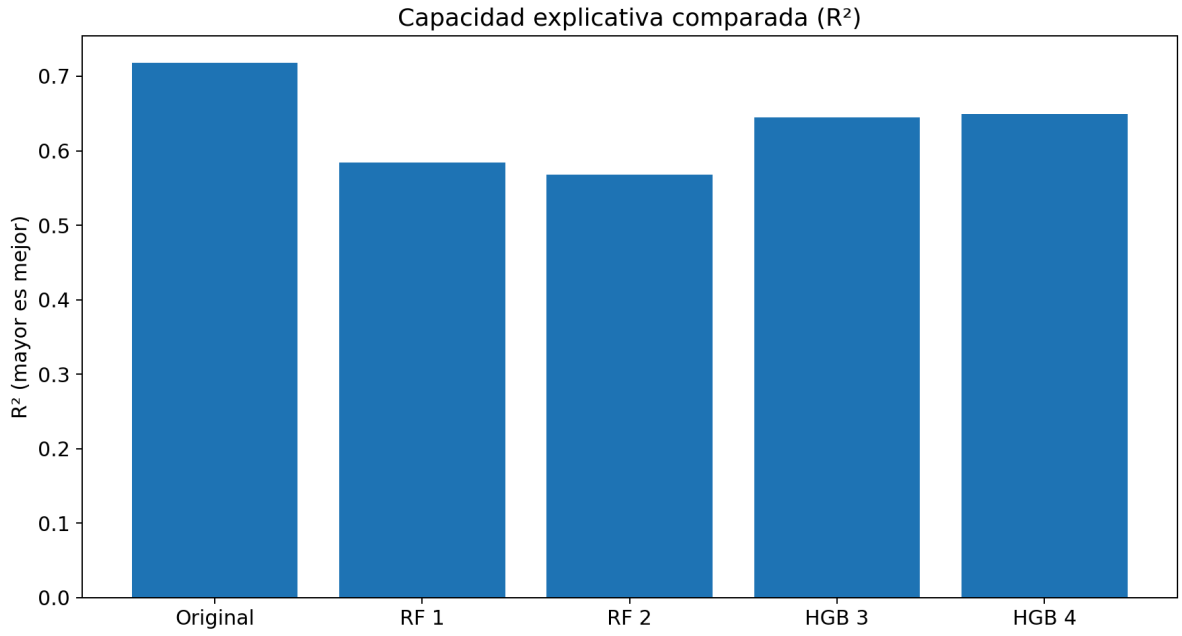
4. Comparación global de los modelos de regresión

Modelo	**MAE**	**RMSE**	**R^2**	**Sesgo reportado**
Modelo original: lineal + duración²	5.75	7.15	0.718	+0.26
Random Forest 1	6.96	8.69	0.584	+2.09
Random Forest 2	7.10	8.85	0.568	+2.29
HistGradientBoosting 3	6.36	8.03	0.645	+1.96
HistGradientBoosting 4	6.39	7.98	0.649	+2.06



El modelo original tiene un MAE de 5,75, lo que representa un error absoluto promedio de aproximadamente 5,75 puntos de popularidad en el conjunto de prueba. La línea base por género presenta MAE=10,44. La reducción del MAE del modelo original respecto a la línea base es aproximadamente 44,9%: (10,44 − 5,75) / 10,44.





El R^2 de 0,718 del modelo original es superior al de los experimentos modificados (0,568–0,649), lo que indica que explica una mayor proporción de la variabilidad observada en este conjunto de prueba. Este indicador no significa que el modelo acierte el 71,8% de las predicciones.

5. Análisis individual de los experimentos

5.1 Modelo original: regresión lineal con duración²

El modelo original combina una regresión lineal con una característica derivada de la duración de la canción. En la ficha se identifica como "lineal + duración²". Sus métricas son MAE=5,75, RMSE=7,15, R^2=0,718 y sesgo reportado de +0,26. Frente a la línea base de MAE=10,44, reduce el error promedio en cerca de 44,9%. Además, su sesgo está más cerca de cero que el de los experimentos posteriores, señal de menor desviación sistemática según la convención reportada.

Este resultado muestra que una solución relativamente sencilla, si incorpora una transformación útil y se evalúa correctamente, puede competir con modelos más complejos. La duración al cuadrado permite representar una relación no estrictamente lineal entre duración y popularidad sin abandonar la estructura general de regresión lineal.

5.2 Random Forest 1

Random Forest 1 obtiene MAE=6,96, RMSE=8,69 y R^2=0,584, con sesgo reportado de +2,09. Aunque supera la línea base, queda por detrás del modelo original en las tres métricas principales. Por género, su mayor MAE aparece en urbano (7,44) y el menor en rock (5,98). Pop muestra sesgo +4,56, lo que merece atención porque indica una desviación sistemática considerable en ese segmento, según la convención del documento.

5.3 Random Forest 2

El segundo experimento documenta 500 árboles, profundidad máxima 8 y mínimo de 5 muestras por hoja. Obtiene MAE=7,10, RMSE=8,85, R^2=0,568 y sesgo +2,29. Sus métricas globales son ligeramente peores que las de Random Forest 1. Urbano vuelve a presentar el MAE más alto (7,64), mientras que rock tiene el más bajo (5,93). El sesgo en pop es +4,97 y en urbano +4,05.

La comparación entre los dos Random Forest no evidencia una mejora por los parámetros del segundo experimento. El resultado ilustra que ajustar la configuración de un algoritmo no garantiza una mejora y que la comparación debe basarse en el mismo conjunto de prueba.

5.4 HistGradientBoosting 3

El experimento 3 registra 200 iteraciones, learning_rate=0,05, máximo de 15 hojas y regularización L2=1,0. Obtiene MAE=6,36, RMSE=8,03, R^2=0,645 y sesgo +1,96. Es el mejor de los cuatro experimentos modificados por MAE, y también el que presenta el menor sesgo absoluto entre esos cuatro experimentos. Por género, rock obtiene MAE=5,79 y urbano 6,80; pop tiene sesgo +3,37.

5.5 HistGradientBoosting 4

El experimento 4 registra 300 iteraciones, learning_rate=0,03, máximo de 10 hojas y regularización L2=2,0. Obtiene MAE=6,39, RMSE=7,98, R^2=0,649 y sesgo +2,06. Frente al experimento 3, empeora levemente el MAE en 0,03 puntos, pero mejora el RMSE en 0,05 y el R^2 en 0,004. Esto refleja una compensación entre métricas: el experimento 3 minimiza el error absoluto promedio, mientras que el 4 mejora marginalmente la penalización de errores grandes y la variabilidad explicada. Rock vuelve a tener el menor MAE (5,65) y urbano el mayor (7,02).

6. Rendimiento por género musical



El desglose por género revela diferencias consistentes. En el modelo original, rock registra el menor MAE (5,14) y urbano el mayor (6,03). En los dos Random Forest, rock vuelve a ser el segmento con

menor error y urbano el de mayor error. En HistGradientBoosting 3, rock tiene el menor MAE (5,79), seguido de indie (5,94); urbano tiene el mayor (6,80). En HistGradientBoosting 4, rock alcanza 5,65 y urbano 7,02.

Género	Original MAE	RF1 MAE	RF2 MAE	HGB3 MAE	HGB4 MAE
Electrónica	5.64	6.55	6.60	6.19	6.06
Indie	5.68	7.04	7.16	5.94	6.00
Pop	5.95	7.29	7.55	6.59	6.62
Rock	5.14	5.98	5.93	5.79	5.65
Urbano	6.03	7.44	7.64	6.80	7.02

El patrón de menor error en rock y mayor error en urbano se repite en todos los modelos de regresión registrados. Esto sugiere que el problema de predicción puede ser más difícil en urbano dentro de este conjunto sintético, aunque no demuestra por sí solo por qué ocurre. Para afirmaciones más fuertes habría que revisar la distribución por género, el tamaño de cada segmento, los errores individuales y la estabilidad en otras muestras.

También deben revisarse los sesgos por género, no solo el MAE. En los experimentos Random Forest, pop y urbano muestran sesgos positivos de mayor magnitud. En HistGradientBoosting, el sesgo de pop también es positivo (+3,37 y +3,57) y urbano presenta +2,31 y +2,61. La interpretación exacta de sobreestimación o subestimación requiere confirmar la fórmula del sesgo en el código, ya que la ficha del modelo original y la normalización usada en algunos registros pueden emplear convenciones diferentes.

7. Línea base y valor añadido

La línea base de regresión predice usando la media de popularidad por género calculada en entrenamiento y tiene MAE=10,44. Los cinco modelos reportados presentan MAE inferior a esa referencia. Las reducciones aproximadas frente a la línea base son:

Modelo	MAE	Reducción de MAE frente a baseline
Modelo original: lineal + duración²	5.75	44.9%
Random Forest 1	6.96	33.3%
Random Forest 2	7.10	32.0%
HistGradientBoosting 3	6.36	39.1%
HistGradientBoosting 4	6.39	38.8%

La comparación con la línea base confirma que los modelos capturan información útil más allá de predecir una media por género. Sin embargo, la comparación más relevante para decidir qué modelo conservar es contra el modelo original, porque este ya representa una solución con buen desempeño.

8. Modelo de clasificación: regresión logística

Además de la regresión de popularidad, el documento presenta un modelo de regresión logística para clasificar si una canción será hit. La etiqueta es_hit vale 1 si popularidad >= 70. El modelo utiliza las diez variables de entrada antes descritas y excluye reproducciones_sem1 y popularidad para evitar información posterior al lanzamiento o fuga directa desde la variable que origina la etiqueta.

Indicador	Resultado
Umbral probabilístico	0,27
Costo falso positivo	1
Costo falso negativo	3
Costo total del modelo	99
Costo de línea base (nunca promocionar)	318
Accuracy	0,858 (85,8%)
Precision	0,688 (68,8%)
Recall	0,811 (81,1%)
F1	0,745
TN / FP / FN / TP	270 / 39 / 20 / 86

El costo disminuye en 219 unidades frente a la línea base, una reducción aproximada de 68,9%. La elección de un umbral de 0,27 es coherente con la penalización más alta de falsos negativos (3) frente a falsos positivos (1): el sistema acepta más falsas alarmas con el propósito de no dejar escapar tantos hits potenciales. Esta interpretación depende de que la estructura de costos represente adecuadamente la prioridad del negocio.

8.1 Lectura de la matriz de confusión

- TN=270: canciones no hit correctamente clasificadas como no hit.
- FP=39: canciones que el modelo recomienda como hit, pero no cumplen la definición real.
- FN=20: hits reales que el modelo no identifica.
- TP=86: hits reales identificados correctamente.

La matriz suma 415 observaciones, coincidiendo con el tamaño del conjunto de prueba. El recall de 0,811 indica que se detectó aproximadamente el 81,1% de los hits reales; la precision de 0,688 indica que alrededor del 68,8% de las predicciones positivas correspondieron a hits reales.

8.2 Resultados de clasificación por género

Género	n	Costo	Precision	Recall	F1	TN	FP	FN	TP
Electrónica	69	16	0,611	0,786	0,688	48	7	3	11
Indie	53	14	0,600	0,429	0,500	44	2	4	3
Pop	128	39	0,763	0,744	0,753	80	9	10	29
Rock	67	9	0,538	0,875	0,667	53	6	1	7
Urbano	98	21	0,706	0,947	0,809	45	15	2	36

Urbano tiene el recall más alto (0,947) y F1=0,809, pero también 15 falsos positivos. Rock presenta recall alto (0,875), precision más baja (0,538) y solo un falso negativo. Pop presenta la mayor precision

(0,763) y F1=0,753. Indie es el segmento más débil en detección de hits: recall=0,429 y F1=0,500, por lo que convendría revisar ese segmento antes de adoptar decisiones operativas.

La suma de costos por género (16+14+39+9+21=99) coincide con el costo total. Las métricas por género deben interpretarse junto con el tamaño de cada grupo, porque los segmentos tienen cantidades diferentes de canciones.

9. API y funcionamiento del sistema

9.1 GET /salud

La salida documentada devuelve estado "ok", confirma que el modelo está cargado y reporta la ruta modelo.pkl, el nombre del modelo y la tarea. Es una comprobación operativa: indica que el servicio puede cargar el modelo, pero no evalúa la calidad predictiva.

9.2 GET /modelo

La ficha del modelo devuelve el objetivo, las variables de entrada y excluidas, los periodos y tamaños de entrenamiento/prueba, las métricas globales, los resultados por género, el umbral de decisión, las limitaciones y las versiones del entorno. Esta ficha es una pieza de trazabilidad importante.

9.3 POST /predecir y POST /predecir_lote

POST /predecir recibe las características de una canción y devuelve la popularidad esperada, un rango de referencia, el corte de promoción y una decisión derivada. La evidencia incluye una predicción de 84,8 con rango [79,1; 90,6] y recomendación de promocionar por superar el corte de 65. POST /predecir_lote permite solicitar predicciones para varias canciones, con límite documentado de hasta 1.000 registros por solicitud.

Estas respuestas ilustran la integración del modelo en una API. La predicción de ejemplo es una demostración del endpoint y no una evaluación adicional del rendimiento; para evaluar generalización deben usarse métricas calculadas sobre un conjunto de prueba no usado en entrenamiento.

10. Interpretación orientada al negocio

El sistema propone una regla sencilla para la regresión: recomendar promoción cuando la popularidad estimada supera 65. Ese corte es una decisión de negocio y no una propiedad que el modelo determine por sí solo. En la práctica, una disquera debería combinar la predicción con presupuesto disponible, costos de campaña, margen esperado, incertidumbre y objetivos de catálogo.

Para clasificación, el umbral 0,27 y los costos de falsos positivos y falsos negativos hacen explícito que dejar pasar un hit se considera tres veces más costoso que recomendar una canción que finalmente no sea hit. Esta estructura explica el énfasis en recall. Antes de usarla en producción, los costos deben ser validados con responsables del negocio y con resultados reales.

11. Calidad metodológica, riesgos y limitaciones

- Datos sintéticos: los resultados demuestran el funcionamiento del flujo analítico, pero no garantizan que el modelo funcione igual con datos reales de la industria musical.

- Comparación temporal: la partición 1995–2019 / 2020–2025 es adecuada para simular predicción futura, siempre que todos los modelos se evalúen exactamente sobre las mismas observaciones.
- Fuga de información: excluir reproducciones_sem1 y es_hit de regresión, y excluir popularidad de clasificación, es una decisión metodológica correcta según el momento de predicción declarado.
- Sesgo: la ficha del modelo original reporta sesgo +0,26, mientras que la convención interna de otras fichas puede ser distinta. Antes de una versión final publicable, debe documentarse si sesgo = predicción − valor real o valor real − predicción.
- Selección del modelo: no debe elegirse únicamente por una métrica. MAE refleja error típico; RMSE penaliza errores grandes; R^2 aporta contexto explicativo; sesgo y métricas por segmento ayudan a identificar patrones.
- Importancia de variables: el documento de pruebas no presenta resultados numéricos explícitos de importancia de variables para los modelos de regresión. Por tanto, no se atribuye aquí importancia o causalidad a variables concretas.
- Reproducibilidad: las fichas anotan Python 3.11.9 y scikit-learn 1.6.1 para los experimentos modificados, y Python 3.11.15 y scikit-learn 1.6.1 para el original. Conviene conservar las versiones y parámetros exactos en el entorno de entrega.
- API operativa: un endpoint de salud exitoso confirma disponibilidad, no precisión ni robustez ante entradas fuera de distribución.
- Decisiones de negocio: los cortes de 65 para regresión y 0,27 para clasificación deben revisarse si cambian los costos, el presupuesto o la prevalencia de hits.

12. Recomendación final sobre los modelos

Si la decisión se basa exclusivamente en las métricas registradas en el documento, se recomienda conservar el modelo original lineal + duración² como modelo de referencia principal para regresión: tiene el menor MAE, el menor RMSE, el mayor R^2 y el sesgo más cercano a cero. HistGradientBoosting 3 puede mantenerse como la mejor alternativa de los experimentos propios por MAE, mientras que HistGradientBoosting 4 es una alternativa si se priorizan ligeramente RMSE y R^2 dentro de los experimentos modificados. Ninguno de los dos supera al original en el resumen registrado.

Para clasificación, la regresión logística es prometedora en términos del costo definido: reduce el costo de 318 a 99 y detecta 86 de los 106 hits del conjunto de prueba. Antes de producción, debe comprobarse el costo en datos reales, revisar el desempeño en indie y confirmar que el umbral 0,27 sigue siendo adecuado.

13. Conclusiones

1. El modelo original es el mejor regresor en la comparación registrada, con MAE=5,75, RMSE=7,15 y R^2=0,718.
2. Los cinco modelos mejoran la línea base de regresión de MAE=10,44, pero los modelos modificados no superan al original.
3. HistGradientBoosting 3 ofrece el menor MAE entre los experimentos modificados; HistGradientBoosting 4 mejora marginalmente RMSE y R^2 respecto al experimento 3.

4. Rock muestra de forma consistente el menor MAE de regresión y urbano el mayor, por lo que el análisis por segmentos es relevante para una futura revisión.
5. La clasificación logística reduce el costo de 318 a 99 (aproximadamente 68,9%) con el umbral probabilístico 0,27 y una penalización de falsos negativos triple a la de falsos positivos.
6. La partición temporal y la exclusión de variables no disponibles antes del lanzamiento mejoran la coherencia del diseño de evaluación.
7. Los resultados son demostrativos porque los datos son sintéticos; no permiten afirmar causalidad ni garantizar éxito comercial.